SLEEP STAGING / WEEK 3

睡眠分期课题
新方向与第三周任务

修订版 · 2026 年 11 月 6 日 · 四天实验安排

四项实验在 Sleep-EDF 的跨受试者设置下展开。A 比较睡眠分期基线的标签效率、EEG/EOG 输入和计算成本。B 检验 pooling、diffusion step 与 N1 判别表现。C 比较从同一份 EEGDM 特征读出的 linear head 和 LFT。D 测试睡眠数据上的从零扩散预训练。

共同实验协议

数据与划分 沿用 Sleep-EDF Expanded 的 Sleep Cassette 子集、Fpz-Cz EEG 和水平 EOG、30 秒睡眠 epoch。按受试者划分为 54 人训练、8 人开发验证、16 人封存测试。沿用 W、N1、N2、N3、REM 五类标签和固定 sample_id。

标签与数据权限 使用既有 5 人、14 人标签名单，以 14 人为核心比较。A 额外使用 54 人全标签预算。预训练只读取 training split 的无标签信号。选参、标准化与 checkpoint 选择使用训练侧数据，使用的分期标签计入对应预算。锁定配置后在 8 人开发集上汇总结果。

指标与记录 主指标为 Macro-F1 和 N1 F1，补充 N1 precision/recall、各阶段 F1、混淆矩阵与逐人差值。保存名单、配置、seed、逐段预测及模型版本。置信区间按受试者配对计算，明确开发集反复使用与受试者数的限制。

本轮实验范围

continued adaptation 和 strict cross-modal agreement 暂停追加。SGConv、Mamba、diffusion Transformer、flow matching 和频谱 conditioning 作为下一轮候选。跨数据集方案待训练成本明确后再排期。

依据 11 月 6 日与 Puah Jia Hong 的讨论、前两周实验记录和第三周原方案。LFT 沿用沟通中的名称，论文新版使用 LFM。

实验 A 睡眠分期基线与标签效率

研究问题 同样的分期输入和标签预算下，现有 CNN 与额外的睡眠分期模型分别能达到什么水平，成本有多大?

选择并核查基线

核对现有 CNN 的配置和结果。检查 ContraWR 与 ST-Transformer 的实现、输入模态、划分和预处理，按可运行性选择一个额外模型完成主比较。另一个模型完成协议和实现核查。

A 的结果为全组提供统一的分期参照。训练名单、模态和评价对象对齐后，其他实验的结果才能与这些基线作直接比较。

在三档标签预算下配对比较

标签预算	比较方法	训练重复
5 位受试者	CNN 与选定的额外 baseline	每种方法 3 个配对 seeds
14 位受试者	CNN 与选定的额外 baseline	每种方法 3 个配对 seeds
54 位受试者	同两种方法的全标签参考	每种方法 3 个配对 seeds

目标共 18 格，符合协议的既有结果可以复用。优先完成 5/14 人比较，再补 54 人。若新增模型只支持 EEG，则使用匹配的 EEG-only CNN。双通道结果作为另一组参考。

检验 EOG 的贡献并分析标签效率

在 14 人预算下，用同一个 CNN 做 EEG-only 与 EEG+EOG 对照，共 3 个配对 seeds。复用主矩阵中匹配的一侧，再补齐另一侧，增加 3 格。比较 N1 和 REM 的收益及错误去向。

绘制 5、14、54 人的 Macro-F1 和 N1 F1 曲线。用逐人差异和各阶段 F1 判断少标签下哪种基线退化更明显。

54 人结果提供全标签参照，5 人和 14 人结果呈现低标签下的表现。EEG/EOG 的同架构对照用于判断加入 EOG 后哪些阶段受益。

核对文献协议与资源成本

记录文献的数据版本、受试者划分、通道、wake trimming、标签预算和数据权限。两种模型按组内统一协议比较。用同一设备和 batch size 测推理吞吐，并记录训练时间、峰值显存和参数量。

> **四天交付** 基线结果与标签效率曲线、EEG/EOG 配对结果、资源表和逐段预测。

实验 B 线性读出与统一评估

研究问题 每秒 std pooling 是否适合 linear probe，改变 diffusion step condition 会带来什么变化?

固定读出并比较 std 与 mean

固定官方 checkpoint、t=1、通道条件和层组。两组都对 30 个时间位置求均值，再用相同的 linear head 训练。先做 14 人预算，再在 5 人预算复验。每档预算各跑 3 个配对 seeds，共 12 格。

两组只改变每秒窗口内的汇总方式。std 概括窗口内激活的波动，mean 保留平均水平。后续的 30 秒聚合与分类设置一致。

每秒 pooling	特征来源
std	复用通过协议核查的现有每秒 std 特征
mean	从原始 activations 计算每秒均值，或重新提取

探索 diffusion step condition

先核对 checkpoint 配置及总步数。以 14 人预算和固定的 std pooling 为起点，用单个 seed 比较 t=1 和两个较大的 t。主比较使用干净输入并仅改变 t condition。追加加噪实验时单列 noise policy 和 noise seed。

分析 N1 判别表现

按标签预算比较 std 与 mean 的 N1 F1、precision、recall 和 AP。按受试者汇总配对差异，并从混淆矩阵检查 N1 被判为 W 或 N2 的变化。

用 N1 分数调整做对照

在 14 人预算选一个预先固定的 seed，分别对 std 和 mean 生成训练名单内按受试者留出的预测。用这些预测确定 N1 分数缩放系数，再固定到开发集比较调整前后的 N1 F1、precision 和 recall。用原始分数的 AP 衡量排序差异。

这组结果可帮助区分两类变化：模型给真实 N1 的分数排序有没有改善，以及调整分数后 N1 的漏报与误报如何变化。

统一评估与交付

> **四天交付** 5/14 人 pooling 结果、t 扫描、N1 分数调整对照、特征索引与统一评估脚本。向 C 提供特征轴和 sample_id 规则，向 D 提供探针接口。

实验 C Pooling 与 LFT 读出

研究问题 在同一个 TUEV-pretrained EEGDM backbone 上，保留 30 秒内的时间位置并用 LFT 融合，是否比现有 temporal mean + linear head 更有效?

先验证特征接口

当前提取器按六个 5 秒窗口处理一个 30 秒睡眠 epoch，再将每秒特征按原顺序拼接。现有单模态缓存为 20 层 × 30 个时间位置 × 128 维。接入官方 LFT 时核对 batch、layer、channel、time 和 pooling/query 相关轴，以及位置编码与层选择。用对齐的 sample_id 做小批次前向与反向检查，确认每个 epoch 输出一组五分类分数。

先完成同一输入下的配对比较

条件	固定配置	读出
C0 基线	官方 checkpoint、t=1、无随机加噪、每秒 std、相同层组与 EEG/EOG 输入	30 秒 temporal mean + linear head
C1 主实验	与 C0 使用同一份 pooled features 和同一标签名单	保留 30 个时间位置的 LFT + classifier

先跑通 14 人标签预算与一个 seed，再补齐 3 个配对 seeds。优先检查 all20 的资源可行性，显存受限时在两组统一使用固定的末层组，例如 last5，并记录 EEG/EOG 各自的层选择。C0 可复用 B 的兼容结果。

扩展顺序

主比较完成后，按资源择一追加 mean + LFT，或在相同噪声策略下检查 t=2、3。先做单 seed 筛查，再决定是否重复。5 人预算、all20 与末层对照，以及六段分别经过 LFT 后再平均，留作单独的扩展比较。

交付与解释

用 **C1 − C0** 判断更换 readout 的实际收益，再用 A 的匹配基线检查任务竞争力。LFT 同时改变参数量和时间信息的利用方式，若有收益，下一轮可用容量接近的轻量时间读出继续拆分原因。

> **四天交付** 输入核验、t=1 的 14 人 linear/LFT 配对结果、逐段预测、N1/REM 错误和训练成本。

实验 D 从零扩散预训练

研究问题 限定训练预算下，小 backbone 在 Sleep-EDF 无标签信号上从零训练后，能否比同架构随机特征提供更有用的分期表征?

固定模型和数据

沿用官方单通道条件化 backbone 的思路。分别从训练池的 Fpz-Cz EEG 和水平 EOG 切出 5 秒单通道片段。两种信号共用 backbone，用不同的模态条件编号。保留合理的 depth，优先适度减小 hidden size。核对残差、条件嵌入和输出维度后锁定配置。

沿用 100→200 Hz、幅度缩放和 staged mu-law。登记采样方式、每个 training epoch 实际覆盖的 5 秒窗口与模态数、timestep sampling、noise schedule、denoising target 及 batch size。

先测速再定训练规模

步骤 1 用固定的几百步检查端到端吞吐、I/O、峰值显存、有限 loss、梯度和参数更新。在固定诊断样本与噪声设置上观察趋势。

步骤 2 根据稳态吞吐判断完整 training epoch 的成本。可承担时实测一轮。也可用代表性批次的耗时和采样器的每轮步数估算。报告估算假设、50/100/200 epochs 的时间和实际 GPU 小时。

步骤 3 按四天内可用的 GPU 时段预先固定更新数与 checkpoint，为第 4 天的探针训练留时间。耗时可控时使用完整 training split。若需缩至约 50%，在各 training participant 内固定抽取窗口，记录比例、样本数和 seed。

最小下游对照

保存同一初始化的 **random-init** 和 **pilot-pretrained** checkpoint。冻结两者，用相同模态、相同 pooling、训练侧标准化和同一 linear head 配方，在 14 人标签预算下跑配对比较。目标 3 个 head seeds，另记 backbone 训练 seed。单套预训练按 pilot 报告，head seeds 用于观察分类头波动。

用同一协议报告 Macro-F1、N1 F1、逐人变化和训练成本。固定训练预算下的读出结果提供扩大实验的依据，预训练 loss 和测速用于判断训练可行性。

> **四天交付** 预训练配置、样本清单、测速与成本、短训 checkpoint 和配对探针。按实际完成步数标注探索性结果。

四天执行节奏与交接

日期	A / B	C / D
第 1 天	A 选额外 baseline 并核对旧结果。B 锁定名单、指标和接口，启动 mean 特征提取。	C 核验 LFT 输入和训练流程。D 跑通小 backbone 并测速，定短训预算。
第 2 天	A 跑 5/14 人基线。B 完成 14 人 std/mean 对照，准备 N1 分数调整。	C 跑 14 人 linear/LFT 首个配对。D 启动固定预算短训。
第 3 天	A 补 54 人参考与模态对照。B 做 5 人复验、有限 t 扫描和训练侧分数调整。	C 补齐配对 seeds，汇总 N1/REM 错误。D 保存短训权重并提取配对特征。
第 4 天	A 汇总基线、错误和成本。B 完成 N1 分析并统一复评。	C 核对同特征比较。D 完成随机权重/短训权重的配对探针。全组各交一张结果表和简短结论。

若共享 GPU，第 1 天按实测耗时为四组锁定时段。A 优先完成 5/14 人比较，B 优先完成 14 人 pooling 主对照。C 优先完成 t=1 配对，D 给第 4 天的配对探针预留时间。各组按预算补充扩展实验。

关键交接

B → C t=1 的 std/mean 特征、sample_id、模态与层轴定义，以及兼容的 linear head 基线结果。

C → B LFT 入口和官方 extractor 适配说明。额外 t 配置记录实际加噪策略。

B → D 提供线性探针和统一评分入口。核对特征形状、sample_id 和数据权限，使用训练侧标准化。

A / C / D → B 固定配置、预测文件与模型来源。B 按 sample_id 核对覆盖并汇总所有实验。

在运行前固定主要对照和结果解释规则。以配对变化和受试者层面证据讨论结论，记录与主实验分开的探索性结果。